

课程作业 3

尧祥临 202518023406038 前沿交叉科学学院

1 任务介绍

本次作业旨在构建一个基于私有知识库的问答系统（RAG），主要的要求分为三层：

1. 应用构建平台 Dify，快速部署对话问答系统。
2. 通过 Ollama 在本地部署推理大模型和嵌入模型实现数据的隐私保护和本地化运行。
3. 在完成基础 RAG 系统后，尝试基于知识图谱的检索增强生成。

由于在第三层的知识图谱构建中遇到了一些环境配置的问题，导致未能成功实现该部分内容，未来会继续探索实现，但是在这一次作业中暂时只完成前两层的任务。


2 环境配置与模型选择

2.1 Dify 环境搭建

按照 ppt 要求，我在 Windows 10 系统的 WSL2 子系统中，首先配置了 Docker 环境，具体而言包括安装 Docker Desktop for Windows，并启用 WSL2 后端支持。然后在 WSL2 中安装 DockerCLI 和 Docker Compose 插件。之后，在 docker 中拉取并运行 Dify 的 Docker 镜像，实现 Dify 平台的本地部署。完成后，通过浏览器访问 <http://localhost/install>，成功进入 Dify 平台首页。

2.2 本地模型部署 (Ollama)

课件中建议第一层使用 deepseek 的 API，但考虑到本地硬件资源允许，这里选择跳过第一层基于 API 的问答系统，而是直接利用 Ollama 在本地部署大语言模型以及嵌入模型。其中大语言模型采用推荐的 deepseek-r1:7b，嵌入模型同样采用了推荐的 nomic-embed-text:v1.5，该模型用于将知识库文本转化为向量，是实现 RAG 检索的关键。



NAME	ID	SIZE	MODIFIED
nomic-embed-text:v1.5	0a109f422b47	274 MB	10 days ago
deepseek-r1:7b	755ced02ce7b	4.7 GB	10 days ago

图 1: Ollama 本地模型列表

2.3 Dify 与 Ollama 的连接

为了让运行在 Docker 容器内的 Dify 能够访问宿主机的 Ollama 服务，这里需要在 Dify 的模型供应商设置中，将 Base URL 配置为 <http://host.docker.internal:11434>。配置完成后，成功添加了 LLM 和 Text Embedding 模型。




图 2: Dify 模型配置

3 知识库构建与对话效果展示

3.1 知识库构建

在 Dify 的知识库界面中创建了名为“复杂网络的统计描述”新知识库，并上传了相关的 PDF 格式的文献文档作为知识库的原始数据。其中在上传文件的时候，选择了通用的分段模式，同时设置为高质量索引模式，调用本地部署好的嵌入模型来处理文档，并设置为向量检索，Top K 为 3，Score 为阈值为 0.5。




图 3: 知识库构建

3.2 应用编排与对话测试

在 Dify 的工作室中创建了一个“知识问答系统 v1.0”的应用，使用本地部署的 deepseek 模型，并关联了上述构建的知识库。配置完成后开始进行对话测试，经过几个问题的尝试，我发现了当前问答系统存在的一些现象和问题。

如图 4 所示，当我询问模型“介数中心性是什么？”的时候，模型除了能从知识库中检索到相应的定义和描述，很大一部分的输出内容应该是来自于模型本身的知识储备，说明模型在回答问题时会综合利用检索到的内容和自身的预训练知识。图 5 所示的为模型对于这个问题提供的参考的文献片段，可以看到模型成功地从知识库中检索到了相关内容，并将其作为回答的一部分。

但是并不是所有问题都能够正确检索到结果，如图 6 所示，当询问模型“复杂网络的效率是什么？”的时候，模型虽然根据其预训练知识给出了一个合理的定义，但并没有从知识库中检索到内容实际上都并不相关。例如图 7 所示的三个结果，模型实际上检索的关键词是“复杂网络”，而并非是问题中更关键的“效率”。事实上，这个问题在知识库中来自一篇英文文献，图所示的为在英文文献中该概念对应的位置，说明当前的知识库构建和检索机制在处理多语言文档时还存在一定的不足，这更多可能与两个本地部署的模型对于多语言的支持能力不够强有关。

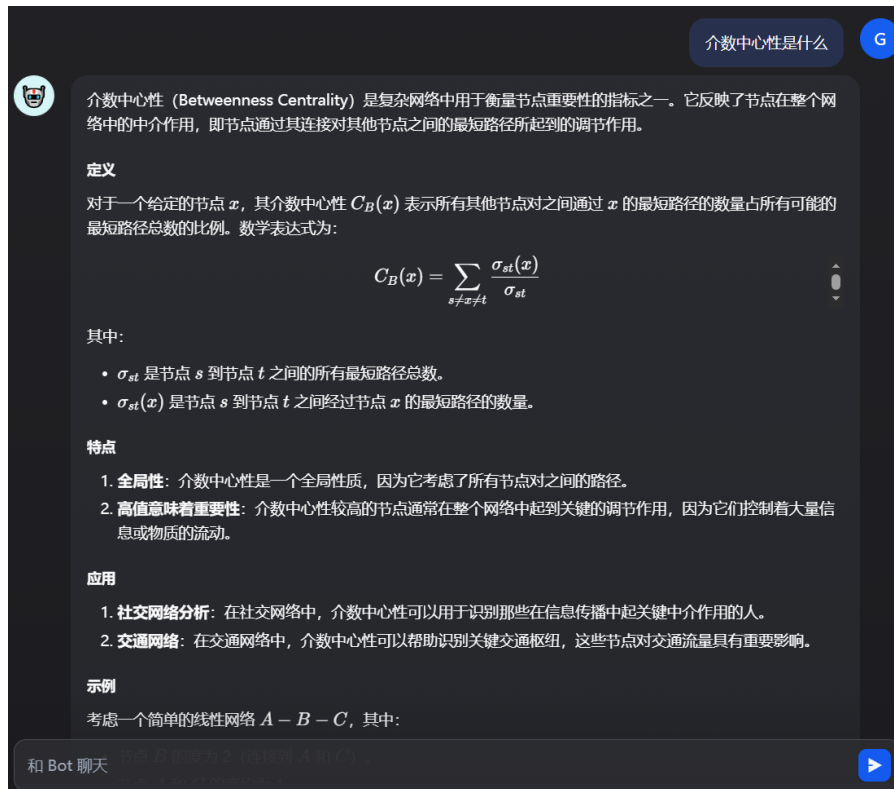


图 4: 第一个问题

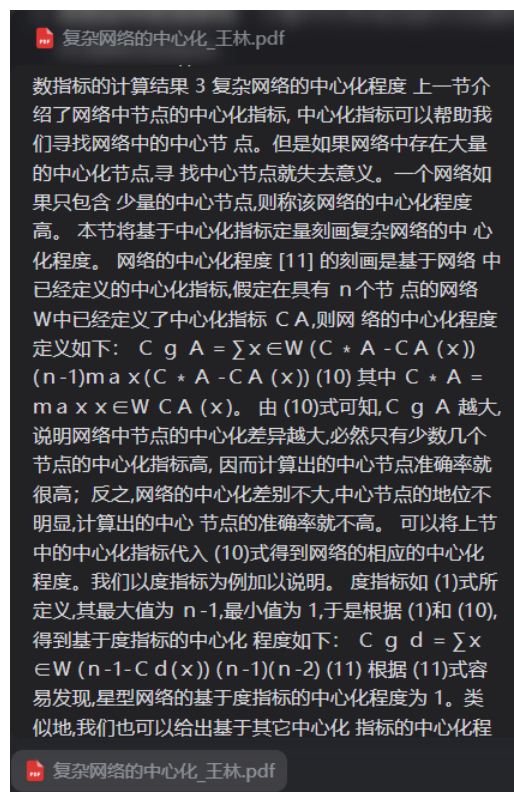


图 5: 第一个问题的文献片段检索结果

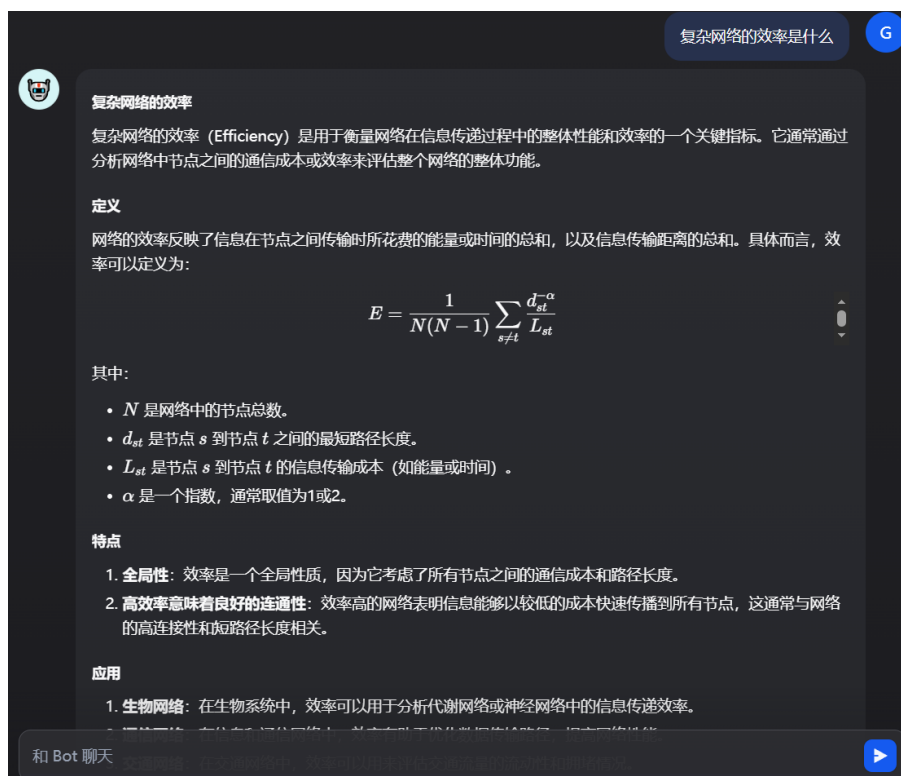


图 6: 第二个问题

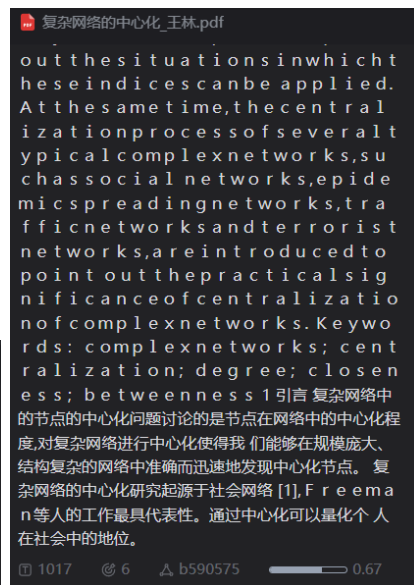
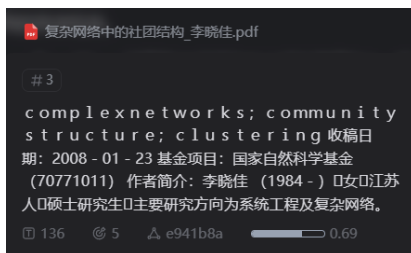



图 7: 第二个问题的文献片段检索结果

A problem with this definition is that it diverges if there are unconnected vertices in the network. To circumvent this problem, only connected pairs of vertices are included in the sum. This avoids the divergence, but introduces a distortion for networks with many unconnected pairs of vertices, which will show a small value of average distance, expected only for networks with a high number of connections. Latora and Marchiori [67] proposed a closely related measurement that they called *global efficiency*:

$$E = \frac{1}{N(N-1)} \sum_{i \neq j} \frac{1}{d_{ij}}, \quad (14)$$

where the sum takes all pairs of vertices into account. This measurement quantifies the efficiency of the network in sending information between vertices, assuming

图 8: 复杂网络的效率的定义在英文文献中的位置

4 总结

本次作业成功搭建了一套完全基于本地环境的 RAG 知识问答系统。实现了 Dify 平台与 Ollama 本地模型的集成;在完成基础 RAG 构建后,我尝试进一步探索基于知识图谱的检索增强生成。在 WSL2 环境中配置 Python 服务端并尝试构建图谱索引时,遇到一些版本兼容性问题,导致服务无法稳定运行。鉴于基础 RAG 系统已满足作业核心需求,因此本次报告主要展示基于向量检索的成果,之后若有机会会继续完善知识图谱部分。